**Assignment 4 : Data Visualization**

**2016314364 박수헌**

UCI Machine Learning Repository에서 Dry Bean Dataset을 선택했다. 총 데이터 instance의 개수는 13611이며, 각 instance 마다 attribute의 개수는 17개이다. 그 중 마지막 한 개는 class로 어떤 종류의 dry bean인지에 대한 정보를 갖고 있다. Class로는 Seker, Barbunya, Bombay, Cali, Dermosan, Horoz, Sira가 있다. 따라서 이는 16개의 정수, 실수의 attribute 값들을 가지는 classification 문제인 것을 알 수 있었다. attribute들로는 area, perimeter, major/minor axis length, aspect ratio 등등이 있었다.

우선 dataset의 파일이 xlsx 파일이었으므로, 이를 csv 파일로 변환했다. 그 후, 이 파일을 읽어 들여, 각 줄에 대해 마지막 attribute는 label이므로, y라는 list에 넣어 저장했고, 나머지는 x라는 list에 float 형식으로 넣어 저장했다.

그 후, train_test_split을 이용해 전체데이터셋의 25퍼센트를 test set으로 분리했다. Test set과 train set의 attribute 값들 모두 standard scaler를 이용해 scaling해주었다. 그래프로 쉽게 보이게 하기 위해, PCA와 tSNE의 n_components들을 모두 2로 설정했다. 그에 따른 결과는 아래와 같았다. x축과 y축은 각각 2차원으로 축소된 attribute들 두 개를 나타낸다. 그에 따른 label값은 점들의 색깔로 나타냈다. 점들의 범례는 차트의 우상단에 색깔별로 표기되어 있다.

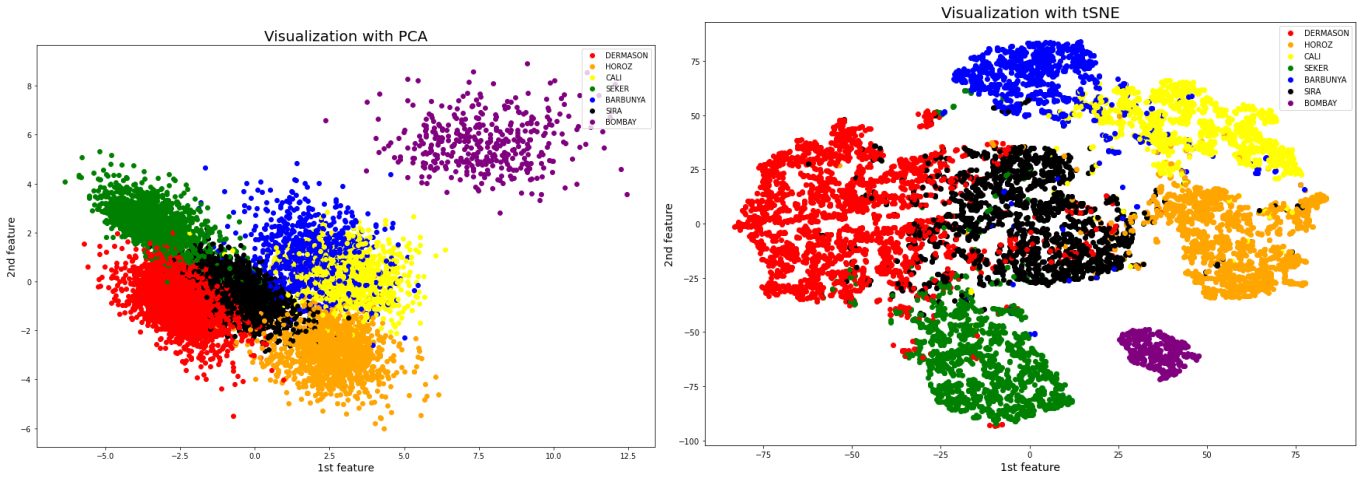


우선, 각 결과의 x축과 y축의 범위를 보면, PCA를 활용했을 때는 폭이 20을 넘지 않았다. 하지만 tSNE를 사용했을 때에는 폭이 x, y축 모두 150이 넘는 수치를 보였다. 그럼에도 불구하고 PCA를 활용한 그래프에서 점들이 더 잘 밀집해 있는 모습을 볼 수 있었다. 또한, 겹치는 영역이 존재하긴 하지만 tSNE에 비교해보았을 때는 비교적 확실한 경계선을 가지고 있다. 즉, 이 데이터셋의 compression 방법으로는 PCA가 더 알맞다는 것을 알아냈다.

tSNE 방법은 가까운 데이터들은 가깝게, 멀리 있는 데이터들은 더 멀어지게 차원을 축소한다. 따라서, 다른 데이터들에 비해 확연하게 멀리 떨어져 있던 BOMBAY를 보면 그 차이를 알 수 있다. PCA는 전체적으로 꽤나 잘 분리되어 보이지만, BOMBAY class를 더 잘 구별해낸 것은 tSNE라고 볼 수 있다. 원래 멀리 있던 데이터를 확실히 구별해내는 데에는 tSNE가 더 나은 성능을 보인다는 것을 알아냈다.

```
import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

file = open('Dry_Bean_Dataset.csv')
x = list()
y = list()
first = file.readline()
while True:
  data = file.readline()
  if data == '' :
    break
  data_split = data.split(',')
  y.append(data_split[-1][1:-2])
  data_split.pop()
  temp = list()
  for i in data_split:
    temp.append(i[1:-1])
  x.append(temp)

x_train,x_test, y_train,y_test = train_test_split(x,y,stratify=y, random_state = 10
16)

scaler = StandardScaler()
scaler.fit(x_train)
x_train_sc = scaler.transform(x_train)
x_test_sc = scaler.transform(x_test)

pca = PCA(n_components=2)
pca.fit(x_train_sc)

x_train_pca = pca.transform(x_train_sc)
x_test_pca = pca.transform(x_test_sc)

print("Original : {}".format(str(x_train_sc.shape)))
print("Reduced : {}".format(str(x_train_pca.shape)))

color_label = y_train[:]
for i in range(len(color_label)):
  if color_label[i] == 'DERMASON':
    color_label[i] = 'red'
  elif color_label[i] == 'HOROZ':
    color_label[i] = 'orange'
  elif color_label[i] == 'CALI':
    color_label[i] = 'yellow'
  elif color_label[i] == 'SEKER':
    color_label[i] = 'green'
  elif color_label[i] == 'BARBUNYA':
    color_label[i] = 'blue'
  elif color_label[i] == 'SIRA':
```

```
    color_label[i] = 'black'
  elif color_label[i] == 'BOMBAY':
    color_label[i] = 'purple'

from matplotlib.lines import Line2D
import matplotlib.pyplot as plt
%matplotlib inline

plt.figure(figsize=(15, 10))
for i in range(len(x_train_pca)):
  plt.scatter(x_train_pca[i][0],
              x_train_pca[i][1],
              c = color_label[i])

legend_elements = [Line2D([0], [0], marker='o', color = 'w', label = 'DERMASON', ma
rkerfacecolor='red', markersize=8),
                   Line2D([0], [0], marker='o', color= 'w', label = 'HOROZ', marker
facecolor = 'orange', markersize=8),
                   Line2D([0], [0], marker='o', color= 'w', label = 'CALI', markerf
acecolor = 'yellow', markersize=8),
                   Line2D([0], [0], marker='o', color= 'w', label = 'SEKER', marker
facecolor = 'green', markersize=8),
                   Line2D([0], [0], marker='o', color= 'w', label = 'BARBUNYA', mar
kerfacecolor = 'blue', markersize=8),
                   Line2D([0], [0], marker='o', color= 'w', label = 'SIRA', markerf
acecolor = 'black', markersize=8),
                   Line2D([0], [0], marker='o', color= 'w', label = 'BOMBAY', marke
rfacecolor = 'purple', markersize=8),]
plt.legend(handles = legend_elements, loc='upper right')
plt.title('Visualization with PCA', fontsize=20)
plt.xlabel('1st feature', fontsize=14)
plt.ylabel('2nd feature', fontsize=14)
plt.show()

from sklearn.manifold import TSNE
tsne = TSNE(random_state = 1016)
x_train_tsne = tsne.fit_transform(x_train_sc)

print("Original : {}".format(str(x_train_sc.shape)))
print("Reduced : {}".format(str(x_train_tsne.shape)))

from matplotlib.lines import Line2D
import matplotlib.pyplot as plt
%matplotlib inline

plt.figure(figsize=(15, 10))
for i in range(len(x_train_tsne)):
  plt.scatter(x_train_tsne[i][0],
              x_train_tsne[i][1],
              c = color_label[i])

legend_elements = [Line2D([0], [0], marker='o', color = 'w', label = 'DERMASON', ma
rkerfacecolor='red', markersize=8),
```

```
                   Line2D([0], [0], marker='o', color= 'w', label = 'HOROZ', marker
facecolor = 'orange', markersize=8),
                   Line2D([0], [0], marker='o', color= 'w', label = 'CALI', markerf
acecolor = 'yellow', markersize=8),
                   Line2D([0], [0], marker='o', color= 'w', label = 'SEKER', marker
facecolor = 'green', markersize=8),
                   Line2D([0], [0], marker='o', color= 'w', label = 'BARBUNYA', mar
kerfacecolor = 'blue', markersize=8),
                   Line2D([0], [0], marker='o', color= 'w', label = 'SIRA', markerf
acecolor = 'black', markersize=8),
                   Line2D([0], [0], marker='o', color= 'w', label = 'BOMBAY', marke
rfacecolor = 'purple', markersize=8),]
plt.legend(handles = legend_elements, loc='upper right')
plt.title('Visualization with tSNE', fontsize=20)
plt.xlabel('1st feature', fontsize=14)
plt.ylabel('2nd feature', fontsize=14)
plt.show()
```